

Clasificación de imágenes satelitales y Post-Procesamiento

Solución Tercer Taller

Integrantes:

Manuel Santiago Lerma Merchán

Docente:
David Zapata

Sensores Remotos
Universidad Nacional de Colombia
Facultad de Minas - Sede Medellín
2024

Universidad Nacional de Colombia
Manuel Santiago Lerma Merchán
Marzo, 2024

Clasificación de imágenes satelitales y post-procesamiento

Solución Tercer taller

Entrega: El estudiante debe hacer entrega de un documento en el cual se pueda evidenciar el seguimiento de estos procesos de una forma clara y ordenada. Se debe realizar para su zona de interés un mapa de coberturas del suelo utilizando una clasificación no supervisada, supervisada, y supervisada con PCA. Compare y discuta los resultados.

También se debe presentar los resultados obtenidos en el proceso de post-procesamiento y filtro del área mínima cartografiable en ArcGIS.

DESARROLLO DEL TALLER

Para la realización de este taller se utilizaron las imágenes del satélite LANDSAT 8 en el área de estudio en los tributarios Río Grande entre los municipios de Santo Domingo y Cisneros. Para hacer la debida clasificación de imágenes se realizó previamente la corrección de valores DN a reflectancia y el recorte sobre el área de interés, empleando la metodología usada en talleres anteriores. Este taller se divide en tres partes; la clasificación digital no supervisada, la clasificación supervisada y Post-Procesamiento, donde se explica el paso a paso por medio de las herramientas como QGIS, GEE y SIG con el objetivo de discutir y comparar los resultados obtenidos.

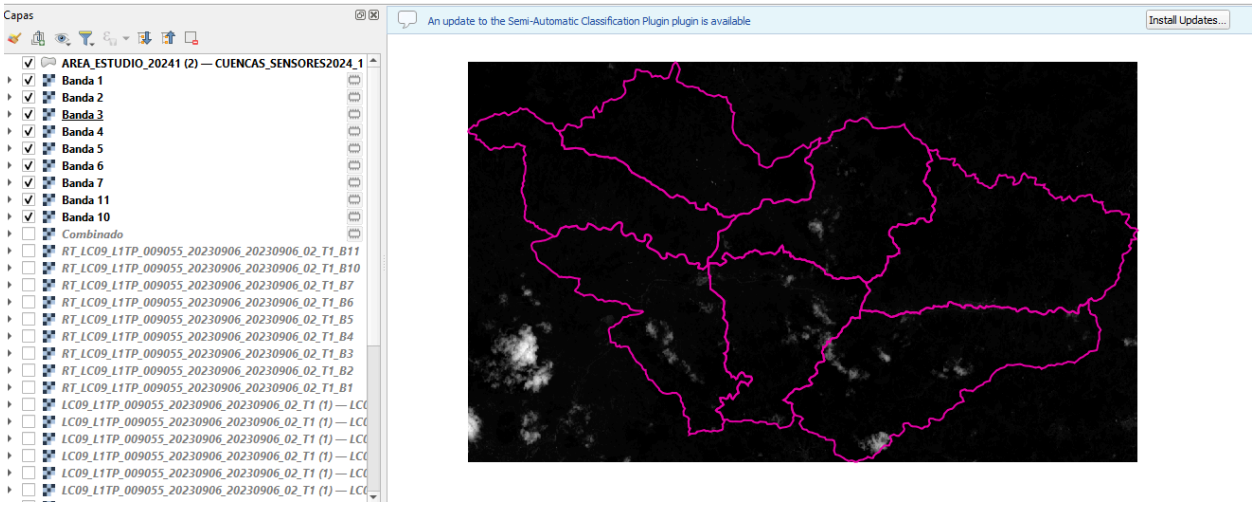


Figura 1. Imágenes Landsat 8 corregidas y recortadas. Fuente propia

1) Clasificación digital no supervisada

1.1) Desde SCP

Nos dirigimos a la Clustering por medio de las siguiente ruta (SCP – Band Processing – Clustering), en éste sitio elegimos: 'banda set', opción donde se puede trabajar las bandas del Landsat 8 que previamente corregimos, en ésta ventana se parametrizaN los datos tal como se muestra en la siguiente imagen.

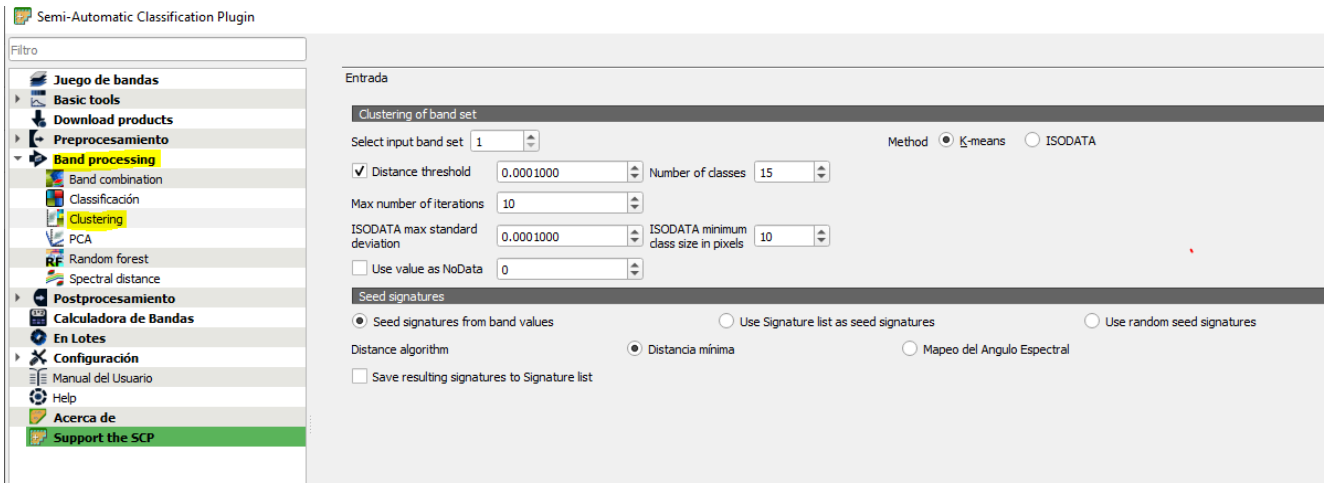


Figura 2. Interfaz Clustering Fuente propia

Una vez seleccionadas las opciones mostradas en la imagen probaremos ambos métodos (K-means e ISODATA) con 15 clases.

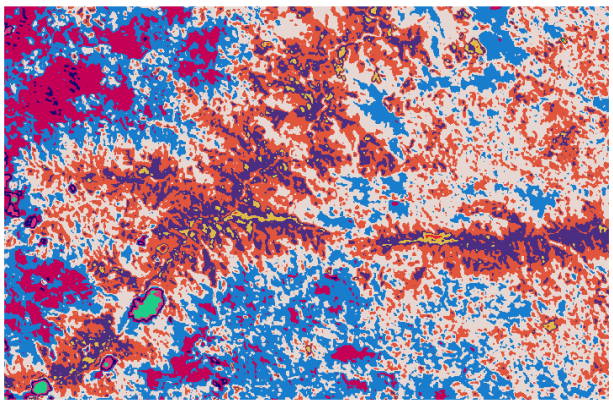


Figura 3. Mapa de Clasificación no supervisada (K-means). Fuente propia

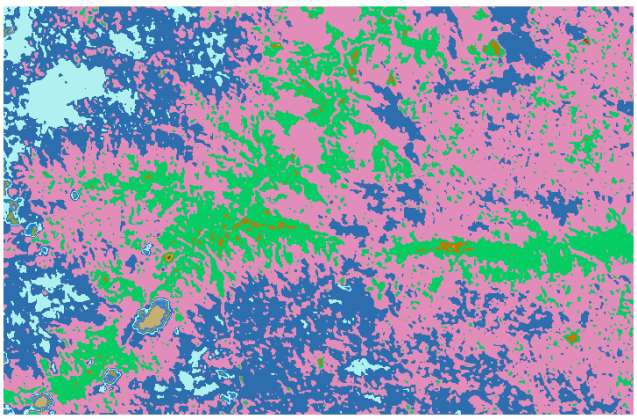


Figura 4. Mapa de Clasificación no supervisada (ISODATA). Fuente propia.

Este mapa de clasificación no supervisada discrimina los diferentes tipos de vegetación: la primera donde esta la vegetación abundante (color fucsia), vegetación media (Color azul), suelos y/o baja vegetación (Color beige y naranja), zonas urbanas (amarillo y rojo), y nubes (color agua marino).	Este mapa de clasificación no supervisada discrimina los diferentes tipos de vegetación, donde ésta vegetación abundante (color azul marino), vegetación media (Color azul), suelos y/o baja vegetación (Color lila y verde), zonas urbanas (marrón), y nubes (amarillo).
Ambas imágenes muestran discriminaciones muy semejantes, sin embargo, presenta un mayor nivel de detalle la imagen que emplea el método de K-means, el cual discrimina las coberturas vegetales de manera más precisa y además presenta más clases que el método Isodata. Por estas razones considero más pertinente el mapa de clasificación no supervisada K-means. Cabe resaltar que ambas imágenes no diferencian claramente los cuerpos de agua.	

1.2) Desde SAGA

Para obtener la clasificación digital no supervisada por este método, debemos descargar el plug in 'Processing Saga NextGen Provider' en la herramienta de complementos de Qgis, una vez descargado por internet 'SAGA GIS' y luego de instalarlo en Qgis, se logró hacer uso de esta herramienta, la cual se ubica en la siguiente ruta: Caja de herramientas de Procesos - SAGA Next Gen - Image analysis - K-means clustering for grids.

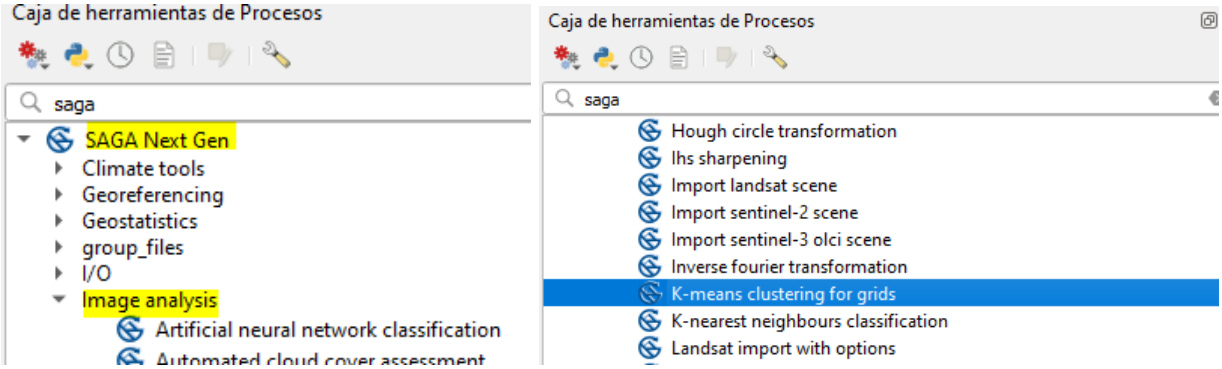


Figura 5.Ingreso a herramienta K-means clustering(SAGA) Fuente propia

Una vez allí en la pestaña de Grids seleccionamos las bandas previamente recortadas y corregidas del Landsat 8 y se configura con los parámetros mostrados en la siguiente imagen:

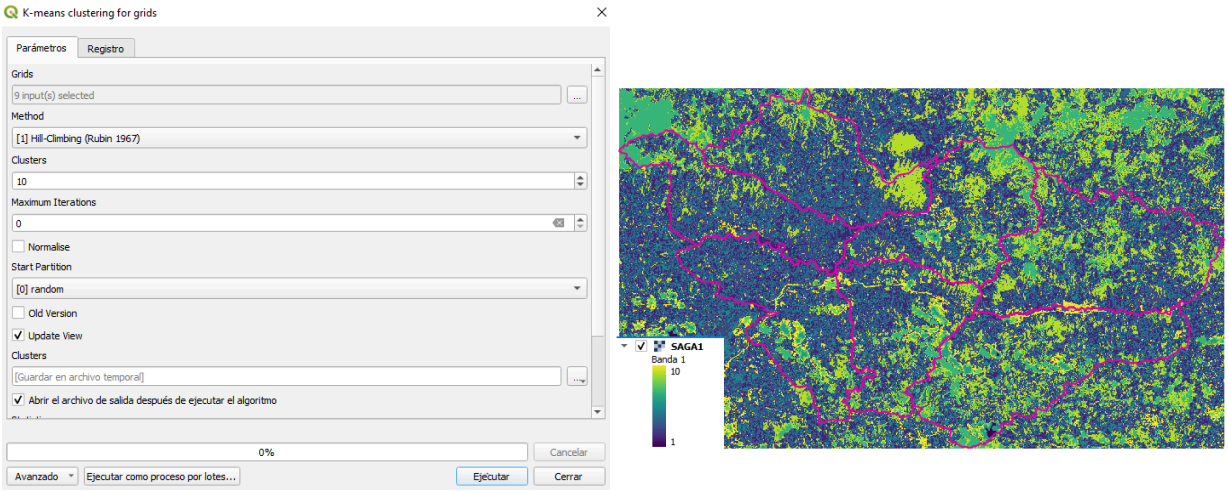


Figura 6. interfaz a herramienta K-means clustering(SAGA) y mapa resultante.Fuente propia.

2) Clasificación digital supervisada

2.1) Procedimiento en QGIS desde SCP

Para la verificación de la clasificación supervisada desde el plug in SCP de QGIS, emplearemos las 9 bandas resultantes de la corrección y realizaremos un entrenamiento sobre la imagen a color natural (4-3-2) del landsat 8, esto se realiza debido a que en la zona de estudio se puede diferenciar zonas desde mucha a poca vegetación, como también los suelos y cuerpos de agua, éstos parámetros se pueden diferenciar en esta combinación, por lo tanto sobre ésto nos basaremos para el entrenamiento.

Por lo anterior, generamos la imagen combinada (4-3-2) y abriremos el panel SCP Dock, luego nos dirigimos a la pestaña ‘Training input’, en ésta ventana escogemos la carpeta donde se guardará el entrenamiento, el cual se clasificará según la siguientes macro-clases: Vegetación abundante, Vegetación, Suelos/Áreas de poca vegetación, Zonas urbanas, Cuerpos de agua y Nubes.

Las siguientes imágenes corresponden a la vista obtenida de aplicar el procedimiento de entrenamiento pos SCP DOCK.

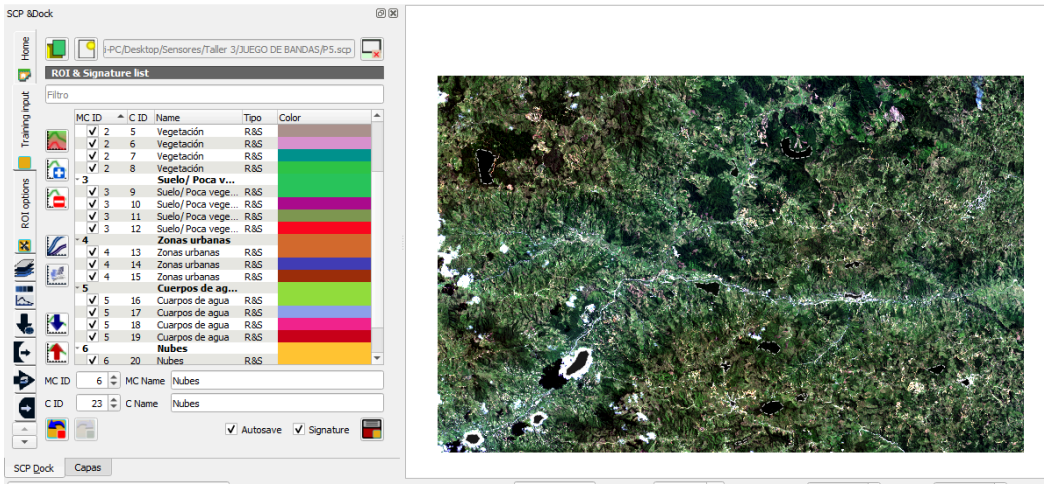


Figura 7. Imagen procedimiento de entrenamiento pos SCP DOCK .Fuente propia.

En la pestaña 'ROI Y Signature list' se puede empezar a trazar polígonos para cada una de las macro-clases y una vez guardados van quedando en la lista, se irá asignando un ID y un nombre a las macro-clases y a las clases que deseamos trabajar; en total se trabajaron con 6 macro-clases y 23 clases.

Para generar la firma espectral de las clases generadas, seleccionamos todas las clases de la lista y luego al dar clic en generar gráfico de Firma Espectral se genera el gráfico, al cual le cambiamos el color de acuerdo a la macro-clase que pertenecía y a cada clase.

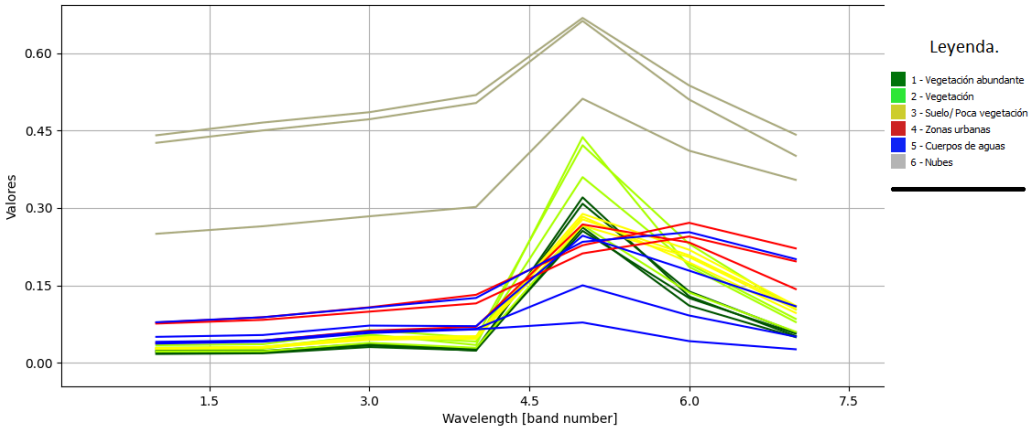


Figura 8. Firma espectral .Fuente propia.

En ésta firma espectral, se puede evidenciar los patrones únicos de reflectancia o emisividad de un material o una superficie en diferentes longitudes de onda del espectro electromagnético. En este caso representado en una gráfica donde el eje X

expresa las diferentes longitudes de onda y el eje Y se refiere al valor de reflectancia, en donde podemos evidenciar que las nubes reflejan mucho más la luz que en las otras macro-clases, al tener mayores valores; mientras que los cuerpos de agua reflejan muy poco y más bien absorben mucho, por lo que tiene valores más bajos. De acuerdo a lo que obtuvimos en un orden de mayor a menor, estas son las macro-clases con mayor reflectancia: Nubes, vegetación, vegetación abundante, suelo/poca vegetación, zonas urbanas y cuerpos de agua.

Por otro lado es posible mejorar los rangos de las firmas espectrales y reducir el número de firmas de celdas espectrales por medio de la funciones from ROI y From Pixel que se encuentran señalados en la imagen mostrada a continuación:

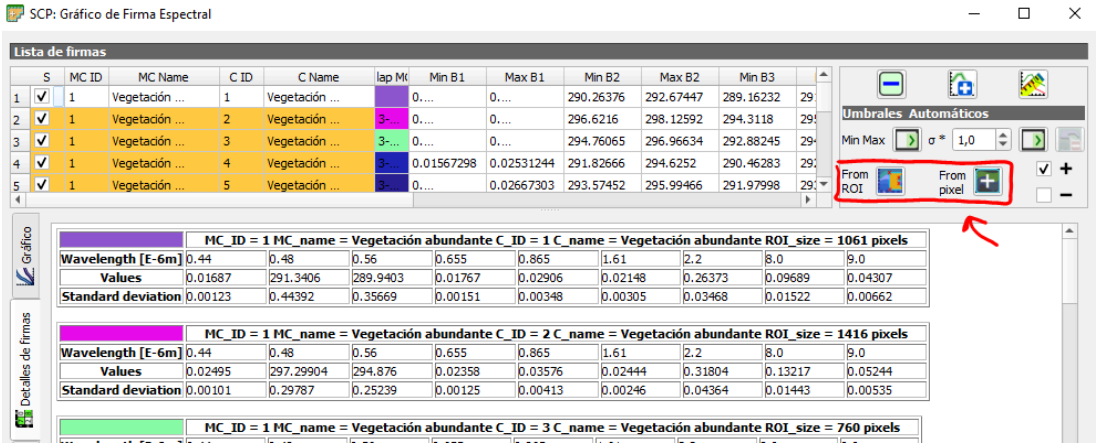


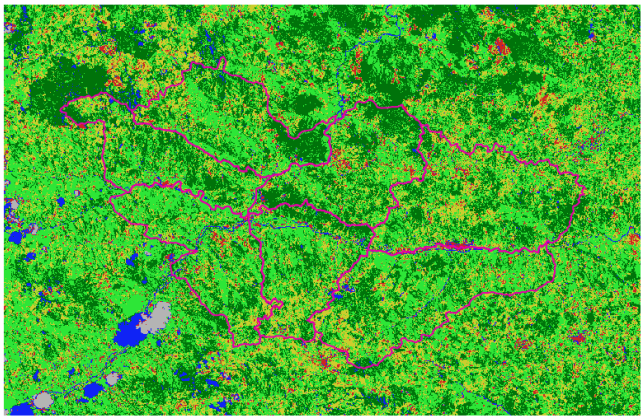
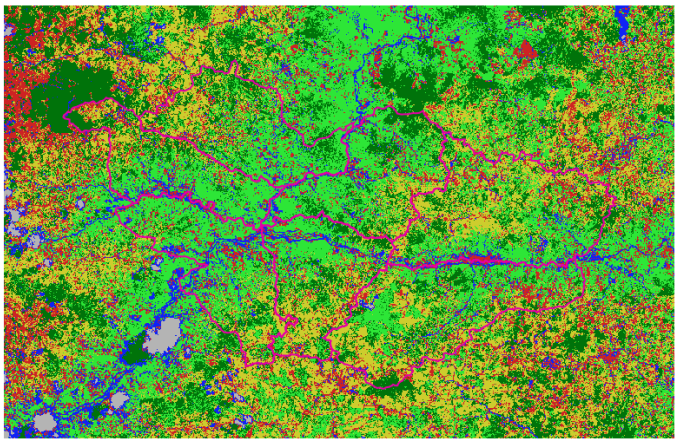
Figura 8. Detalles de la firma espectral .Fuente propia.

También es posible ver otros tipos de características de cada una de las clases generadas en el entrenamiento, si es que se desea profundizar en este aspecto, esto se obtiene en la pestaña: detalles de firmas.

Posteriormente se procede a realizar la clasificación a partir del entrenamiento realizado, para esto, generamos un banda Set donde sólo se incluyen las bandas reflejadas y no las de infrarrojo térmico. Después nos dirigimos a clasificación donde seleccionamos el **band set** recién creado, para éste caso se usa la macro-clase, por lo que seleccionamos la opción '**MC ID'.** En la parte de algoritmos probaremos las tres opciones (Distancia mínima-Distancia máxima-Mapeo del ángulo espectral) y estableceremos algunas diferencias entre ellas.



Figura 9. Interfaz Clasificación .Fuente propia.

Imagen	Leyenda
 *Figura 10. Mapa de clasificación por distancia mínima. Fuente propia.*	0 - Unclassified 1 - Vegetación abundante 2 - Vegetación 3 - Suelo/ Poca vegetación 4 - Zonas urbanas 5 - Cuerpos de aguas 6 - Nubes
 *Figura 11. Mapa de clasificación por distancia máxima. Fuente propia.*	0 - Unclassified 1 - Vegetación abundante 2 - Vegetación 3 - Suelo/ Poca vegetación 4 - Zonas urbanas 5 - Cuerpos de aguas 6 - Nubes

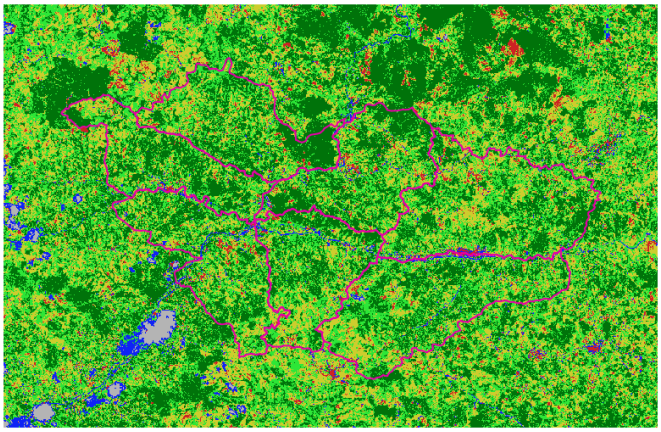


Figura 12. Mapa de clasificación por mapeo del ángulo espectral. Fuente propia.

Análisis:

De los tres mapas elaborados considero que el mejor es el mapa de clasificación por mapeo del ángulo espectral, ya que presenta los mejores datos de las macro- clases, siendo la más precisa; ésto se deduce al comparar el resultado con el mapa de combinacion de color natural. En el caso del mapa de clasificación por distancia máxima, éste discrimina de manera errónea las zonas urbanas y el suelo, detectando ésto, en sitios donde no hay; en el caso de la clasificación por distancia mínima, es una imagen precisa, sin embargo marca cuerpos de agua y zonas urbanas donde no hay o simplemente no hace una distinción tan precisas como el del mapeo angular.

El problemas que tiene el mapa de clasificación por mapeo del ángulo espectral, al igual que las otras clasificaciones, es por las sombras de las nubes las cuales se detectan como cuerpos de agua, esto se debe a que al igual que las sombras, los cuerpos de agua se representa con colores oscuros, por lo que interpretaron las sombras de esa manera, una forma para evitar esto podría haberse corregido creando una nueva macro-clase donde hubiésemos tenido en cuenta éste tipo de sombra para poder realizar la distinción.

→ **Diferencias entre clasificación supervisada y no supervisada:**

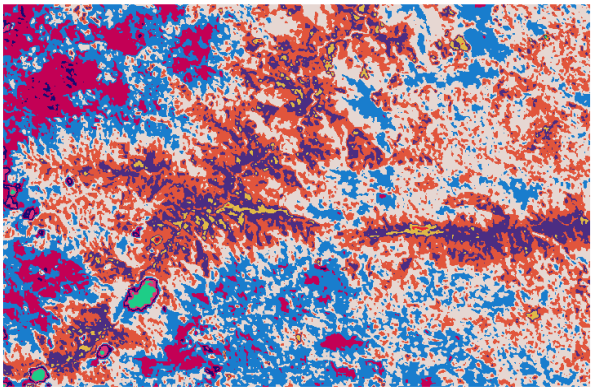


Figura 3. Mapa de Clasificación no supervisada (K-means). Fuente propia

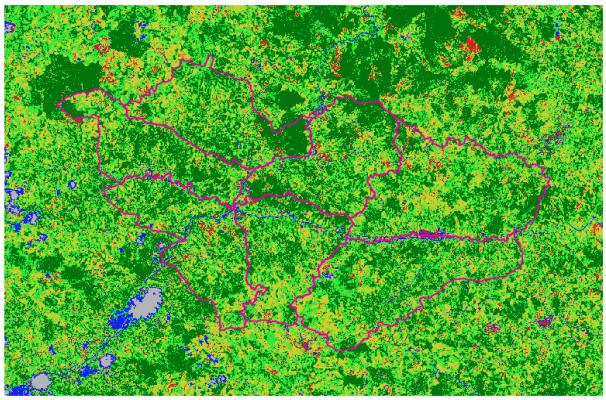


Figura 12. Mapa de clasificación supervisada por mapeo del ángulo espectral. Fuente propia.

La clasificación no supervisada nos proporciona, de manera básica, las formas del terreno, pero no nos permite obtener detalles muy específicos ni identificar las clasificaciones claramente, ya que representa cada color con un número, lo cual debe ser inferido. Por otro lado, la clasificación supervisada nos permite establecer criterios de clasificación, brindando mayor claridad y precisión sobre los diferentes cuerpos, donde podemos seleccionar como macro-clases los cuerpos que deseamos clasificar. Por ejemplo, los cuerpos de agua no son claramente visibles en el mapa de clasificación no supervisada, mientras que en el supervisado sí, debido al entrenamiento que ha recibido. En conclusión, un mejor mapa se obtiene con la clasificación supervisada por las razones mencionadas; sin embargo, esto requiere un tiempo considerable de ejecución cuando las imágenes son complejas o presentan coberturas muy variables. Quizás en algunos casos, si se desea una representación básica del terreno, sea preferible utilizar la imagen no supervisada.

2.2) Procedimiento con PCA en QGIS

Para realizar la clasificación digital supervisada por medio de PCA, accederemos a esta herramienta por medio de ‘Band processing’ en SCP, elegiremos el banda set con el que trabajamos anteriormente, es decir con las bandas reflejadas y en número de componentes elegimos 3, cómo se solicita en el taller.

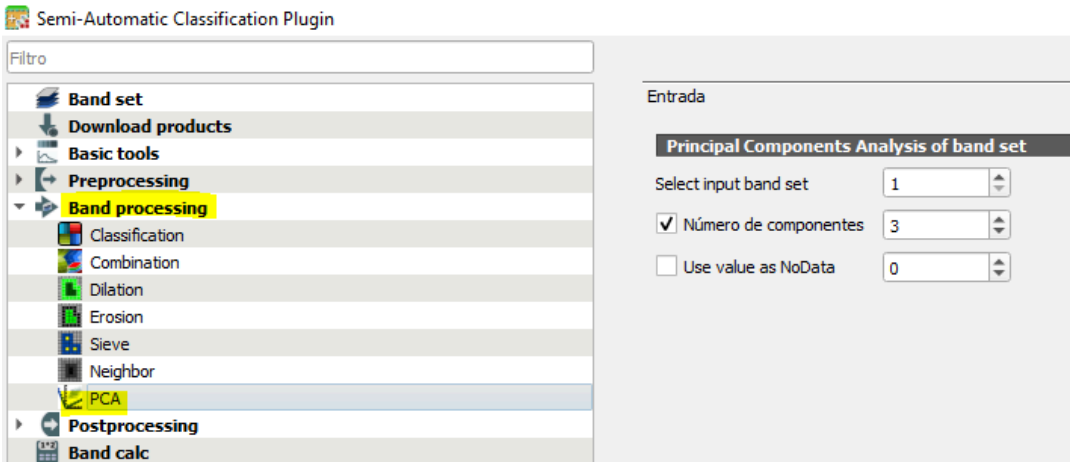


Figura 13. Interfaz PCA. Fuente propia.

Después de correr el programa, se generan 3 nuevas capas que serán los componentes con los que trabajaremos y procederemos a realizar su combinación, usando el **raster virtual** de juego de las 3 bandas, esto fue lo que se obtuvo.

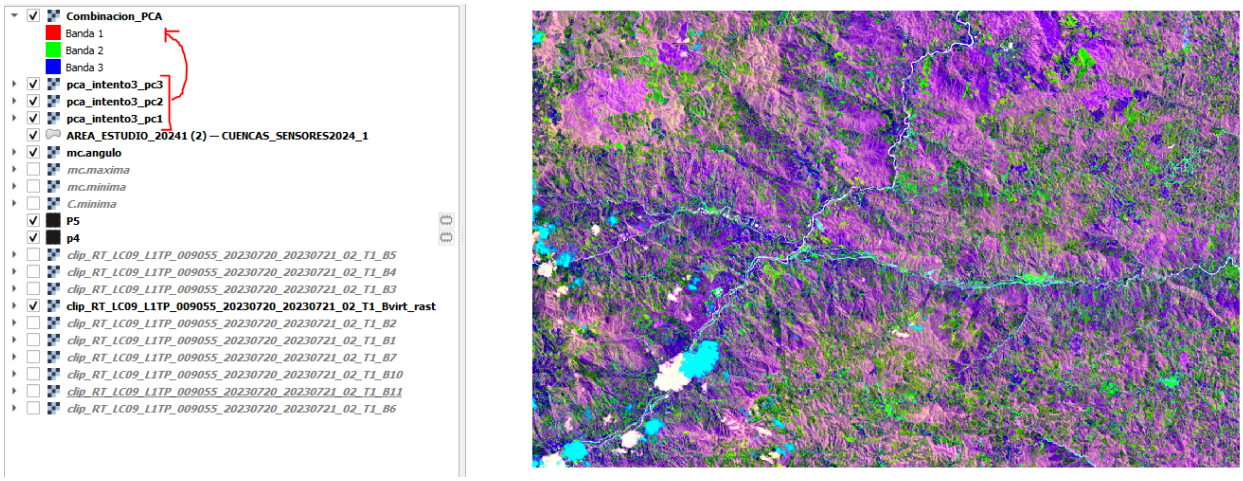


Figura 14. Resultado PCA y combinación de las bandas generadas. Fuente propia.

Repetiremos el procedimiento ya explicado de clasificación digital no supervisada, usando los mismo parámetros que empleamos en nuestros primeros mapas de este tipo y este fue el resultado:

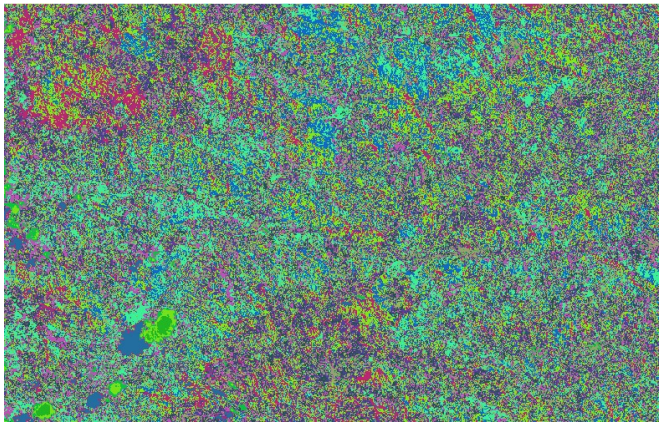


Figura 15. Mapa de Clasificación no supervisada (K-means). Fuente propia

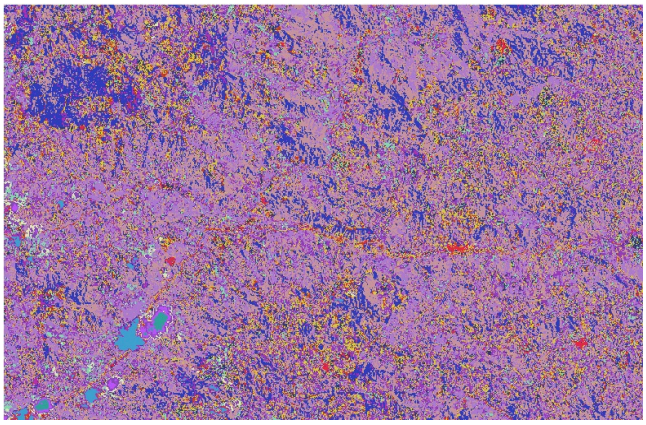


Figura 16. Mapa de Clasificación no supervisada (ISODATA). Fuente propia

En éstas imágenes no supervisadas se diferencian muy pocos materiales, es mejor haber empleado menos números de clases, sin embargos, usamos 15 para comparar éstos mapas con los primeros que realizamos, la diferencia entre ellos radica en que estos mapas no supervisados distinguen mucho mas detalles que los primeros mapas, por lo que probablemente los mapas no supervisados por PCA presentan muchos más detalles que los hecho por la primera metodología, por lo que nos puede revelar más información y ser más preciso.

Nuevamente realizaremos la clasificación digital supervisada empleando los mismos polígonos de entrenamiento que usamos anteriormente y como ya se explicó, se generarán los mapas de clasificación por los 3 algoritmos, empleando las mismas clases y macro-clases.

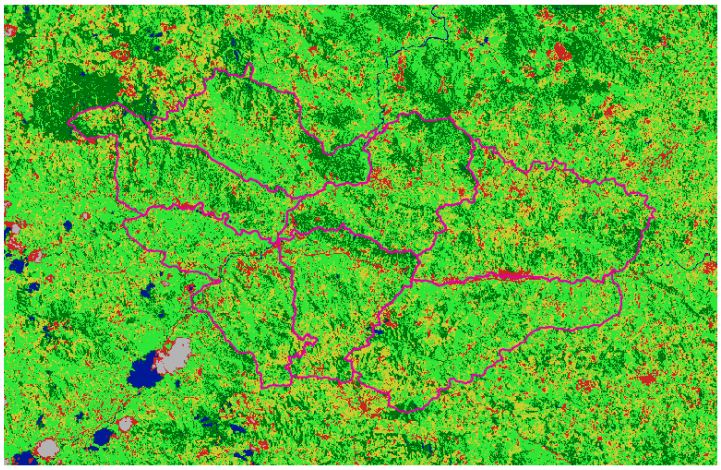
Imagen	Leyenda
	

Figura 17. Mapa de clasificación por distancia mínima. Fuente propia.

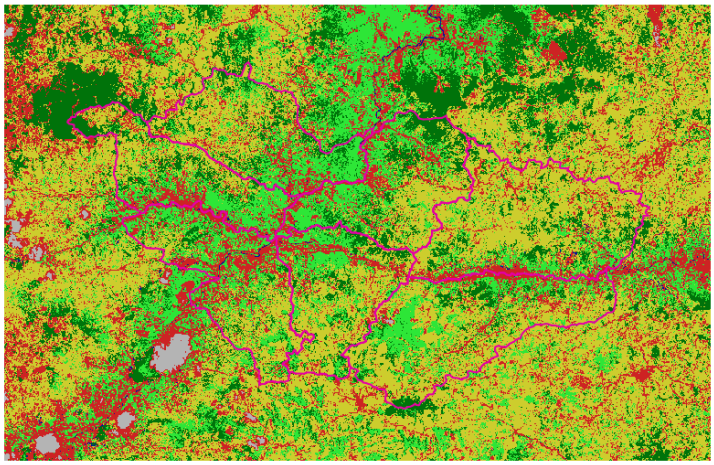


Figura 18. Mapa de clasificación por distancia máxima. Fuente propia.

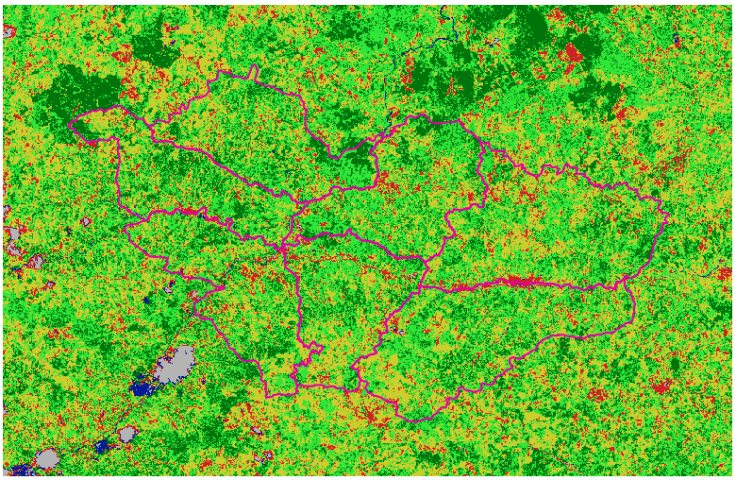


Figura 19. Mapa de clasificación por mapeo del ángulo espectral. Fuente propia

Ésta fue la firma espectral obtenida, la cual es muy parecida a lo que obtuvimos en el anterior entrenamiento, por lo que su análisis será el mismo.

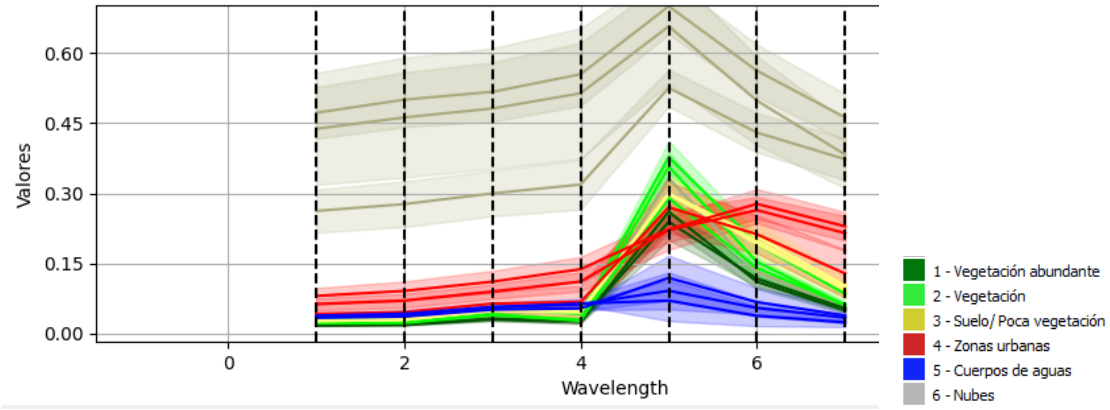


Figura 20.Firma espectral obtenida por PCA. Fuente propia.

Análisis:

En general, las imágenes obtenidas por PCA son muy parecidas a las imágenes clasificadas por la primera metodología, sin embargo, alguna de las diferencias que se logró percibir en el caso de distancia mínima, es que ambas imágenes marcan cuerpos de agua y zonas urbanas donde no hay, sin embargo éstas irregularidades se ven mayormente marcadas en las imágenes del PCA, en ésta última se distingue también ligeros cambios en la vegetación abundante dónde aquí es mayor; mientras que en el caso del mapa de clasificación por distancia máxima, en ambas imágenes marcan zonas urbanas donde no las hay, en la imagen del PCA es mucho más pronunciado, además que ésta imagen no se puede distinguir correctamente los cuerpos de agua, donde se marca muchísimo más el suelo.

Nuevamente el mejor mapa de los tres algoritmos es el del ángulo espectral, el mejor mapa es el primero que realizamos, puesto que en el mapa del PCA, no distingue bien los cuerpos de agua y parece que los confunde con las zonas urbanas y en general difieren un poco en la vegetación abundante, vegetación normal y suelo.

Concluyendo, tenemos que para este ejercicio, los mejores mapas de clasificación se obtuvieron de la primera metodología al usar la combinación natural, pues en los tres algoritmos demostró ser más preciso y exacto que por la herramienta de PCA. Sin embargo, esto no quiere decir que siempre sea así, pues recordemos que los polígonos de entrenamientos que empleamos en esta metodología fueron los mismo que usamos con la imagen natural, por lo que ésto pudo haber influído en el resultado, esto hubiera podido cambiar, si hubiésemos entrenado sobre la imagen combinada y generada por PCA.

2.3) Procedimiento en GEE

Para realizar la clasificación digital supervisada en GEE nos dirigiremos al aplicativo de Google Earth Engine y cargaremos la capa de Landsat TOA Percentile Composite; para trabajar solamente con nuestra área de interés, generamos una máscara dirigiéndonos a la ruta ‘Add computation – Mask Manipulation – Apply mask‘. Una vez allí, seleccionamos como imagen la de Landsat TOA y escogemos únicamente la capa 1 y como tipo de máscara un rectángulo, con ésta opción, podemos delimitar el área de nuestro interés. Una vez seleccionado el rectángulo nos dirigiremos a la opción: **‘Add step – Mask manipulation – Extract mask’**, luego aplicamos, salvamos, y nos aparecerá la máscara generada.

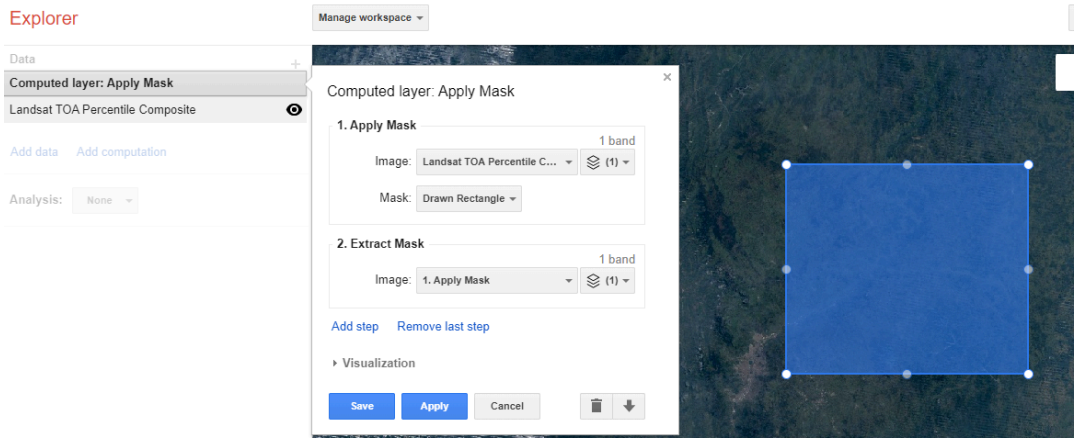


Figura 21. Extracción de máscara sobre Landsat TOA en GEE. Fuente propia.

Ahora cortaremos la imagen del Landsat TOA Percentile Composite sobre la máscara creada, para ésto nos dirigimos a la opción: **'Add computation – Mask Manipulation – Apply Mask'**, dónde seleccionamos la imagen Landsat TOA y luego las bandas del 1 al 7. En la pestaña Mask seleccionamos Ráster, y en la pestaña Ráster seleccionamos nuestra máscara creada, aplicamos y salvamos.

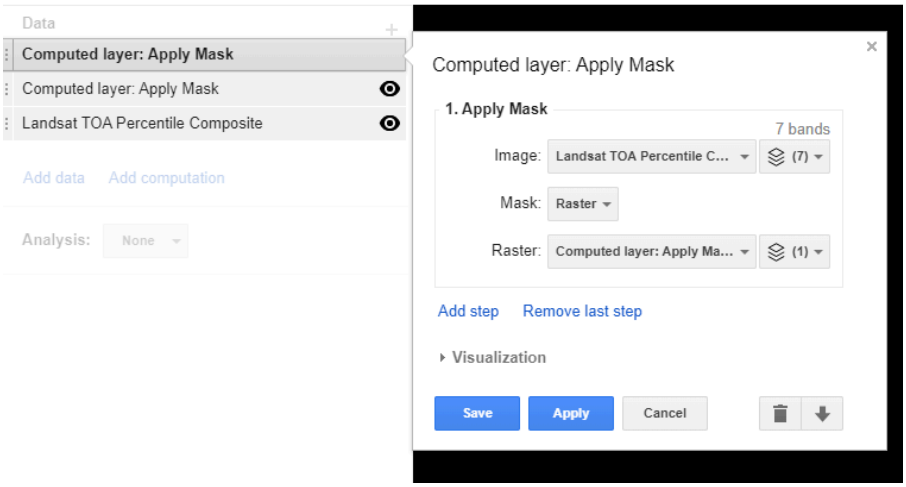


Figura 22. Extracción de máscara. Fuente propia

Ahora empezaremos a realizar nuestra clasificación; para esto buscamos la opción **'hand-drawn points and polygons'** que se encuentra en la barra de búsqueda, seleccionamos y nos aparecerá en la parte inferior izquierda la opción de **add clase**, desde la cual podemos generar nuestras clases y microclases.

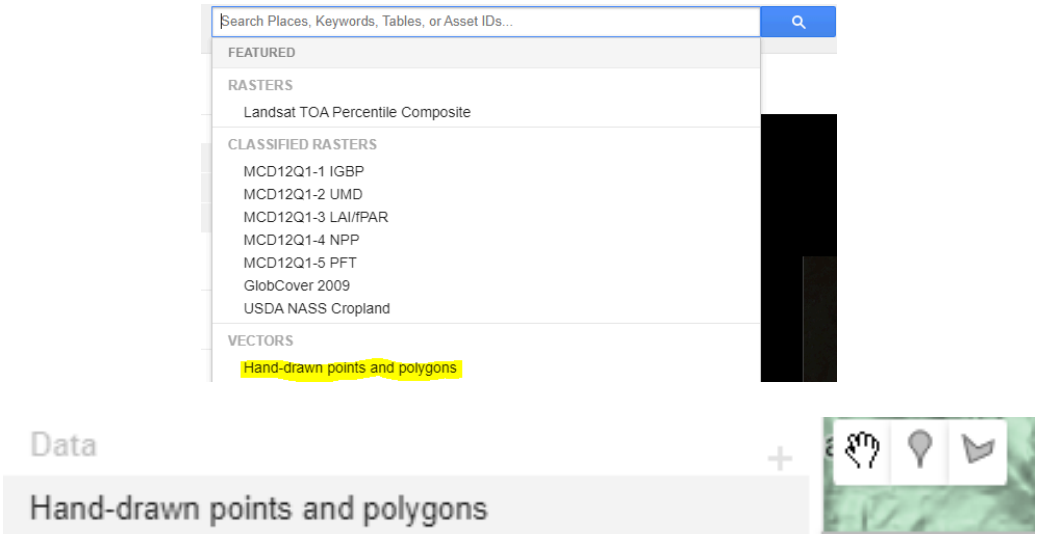


Figura 23. Herramientas para la extracción. Fuente propia

Para el entrenamiento seguiremos trabajando con las mismas macro-clases con las que veníamos trabajando: vegetación abundante, vegetación, Suelos/Áreas de poca vegetación, zonas urbanas y cuerpos de agua, Crearemos Polígonos que encierran cada una de las macro clases propuestas y una vez hecho esto, configuramos las capas que no se van a usar con un 'Don't use'.

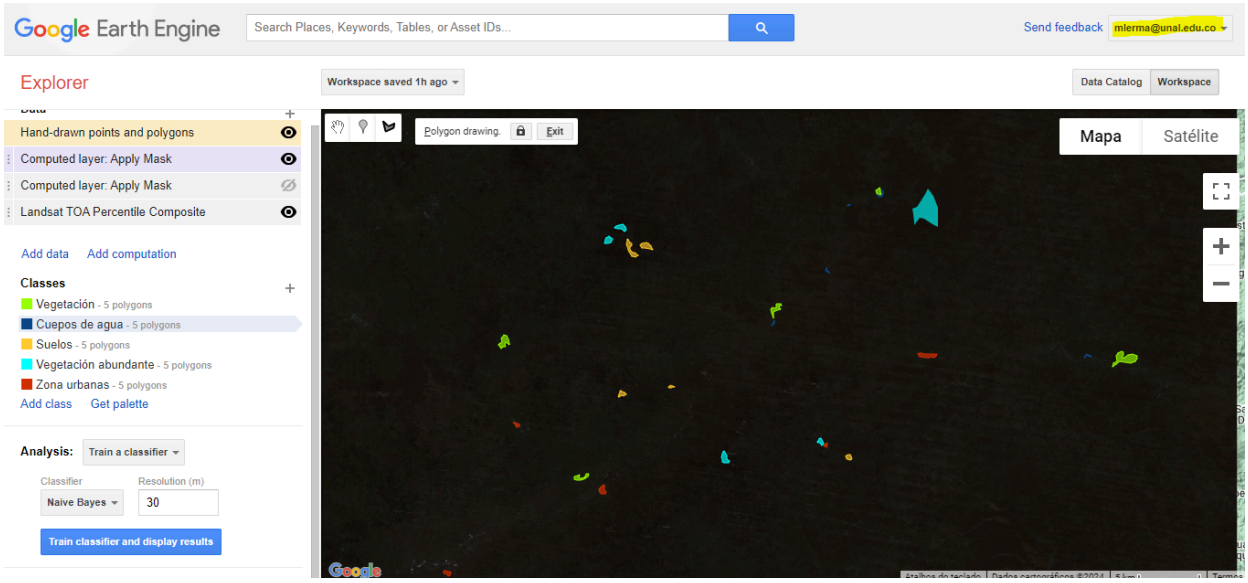


Figura 24. Procedimiento del entrenamiento por GEE. Fuente propia

Una vez realizado ésto, seleccionamos la opción de: **Analysis** y luego '**Train a classifier'** y lo configuramos a una resolución de 30 m, para la clasificación. GEE ofrece 3 opciones de clasificación: Random forest, CART y Naive Bayes; se exploraron las tres opciones y considero como la mejor opción la clasificación de Naive Bayes, pues éste tiene más relación con los mapas de clasificación que se han elaborado en el

trabajo, además que es el más preciso de los tres. Por otro lado, Random forest y CART interpretan zonas urbanas y suelos donde hay de manera muy significativa, por lo que estos métodos no son recomendados, nos quedaremos con la imagen del **Naive Bayes** que podemos observar a continuación con algunas de sus propiedades.

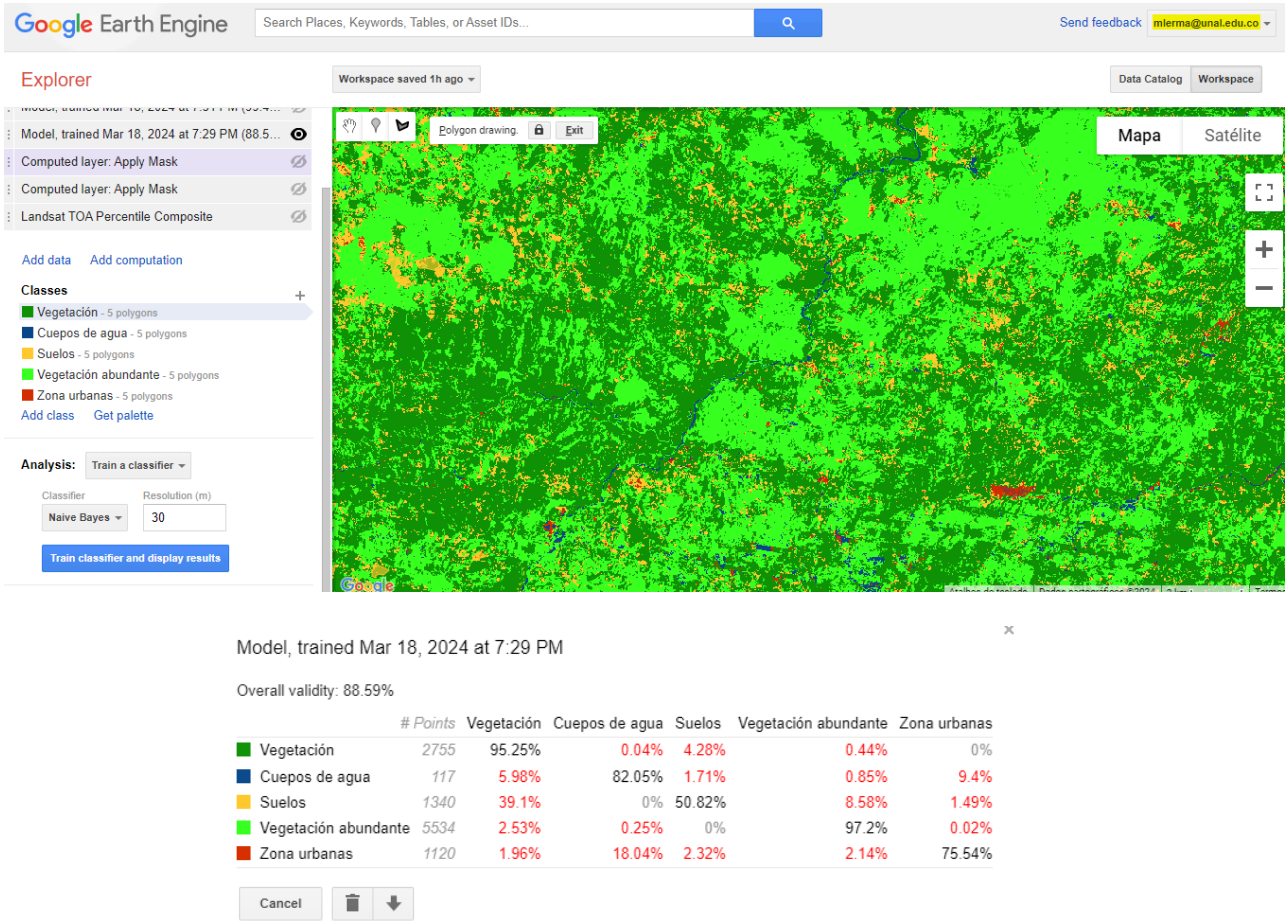


Figura 25. Mapa de clasificación por GEE y algunas de sus características . Fuente propia

A continuación compararemos el mapa de clasificación por mapeo del ángulo espectral trabajado en QGIS con el mapa de clasificación por Naive Bayes trabajado en GEE, ambas imágenes trabajan la misma convención de colores con la que venimos trabajando, para una más cómoda y mejor comparación.

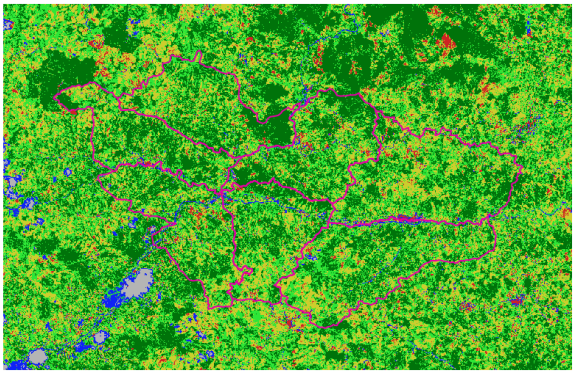


*Figura 12. Mapa de clasificación por mapeo del ángulo espectral por **QGIS**. Fuente propia.*

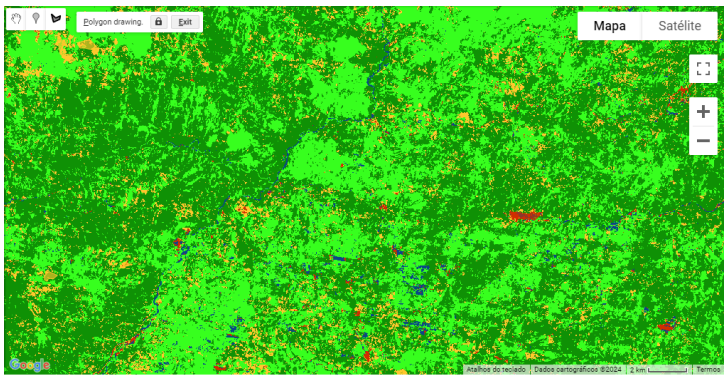


*Figura 25. Mapa de clasificación por **GEE** . Fuente propia*

Análisis:

Comparando ambos mapas, notamos ciertas diferencias, pero lo que más resalta a simple vista es el cambio en la cobertura vegetal. En GEE se detecta mucha más vegetación abundante en comparación con el mapa de QGIS, donde se observa menos vegetación y más suelo denudado. Ésta discrepancia puede explicarse por el hecho de que las imágenes provienen de años diferentes, y la vegetación es un parámetro que varía considerablemente con el tiempo. En éste aspecto, considero más precisa la imagen del Landsat 8 procesada en QGIS, ya que proviene de una imagen reciente del año pasado, lo que podría explicar la menor cantidad de vegetación observada.

Una de las principales ventajas de trabajar en GEE es que su interfaz es más cómoda para el procesamiento y análisis de datos. Además, GEE tiene menos problemas con la presencia de nubes en comparación con las imágenes de Landsat 8, lo que conduce a una mayor precisión en la clasificación. Por otro lado, la imagen de GEE es más precisa en la macro-clase de zonas urbanas, ya que delinea claramente éstas áreas, mientras que el mapa de QGIS identifica varias zonas que no corresponden, lo que podría derivar en una confusión con ciertos tipos de suelo. Por éstas razones, considero más precisa la imagen procesada con Landsat TOA en QGIS.

En conclusión, clasificar utilizando GEE es más cómodo y puede ofrecer una mejor precisión, que hacerlo con imágenes de Landsat 8 en QGIS; sin embargo, con éste último tenemos la certeza de estar trabajando con imágenes recientes, mientras que en GEE no siempre es así. Considero que es preferible trabajar con imágenes recientes, ya que proporcionan una representación más precisa de la realidad en el terreno. Por lo tanto, la herramienta no debe verse como la principal, sino más bien como un complemento de la información en el proceso de clasificación. En casos de inconsistencia o presencia de nubes, el uso de imágenes de GEE puede proporcionar una idea más clara de esas áreas y su contenido.

3) Post-Procesamiento

3.1. Desde SCP.

Como Post-procesamiento en QGIS exploramos dentro de las herramientas de SCP dos funciones llamadas Dilatación de la clasificación y Erosión de la clasificación, en donde trabajaremos sobre las imágenes que ya clasificamos anteriormente. Tomamos un valor de clase de 2, que en nuestros mapas de clasificación está representado por la vegetación y veremos que resulta.

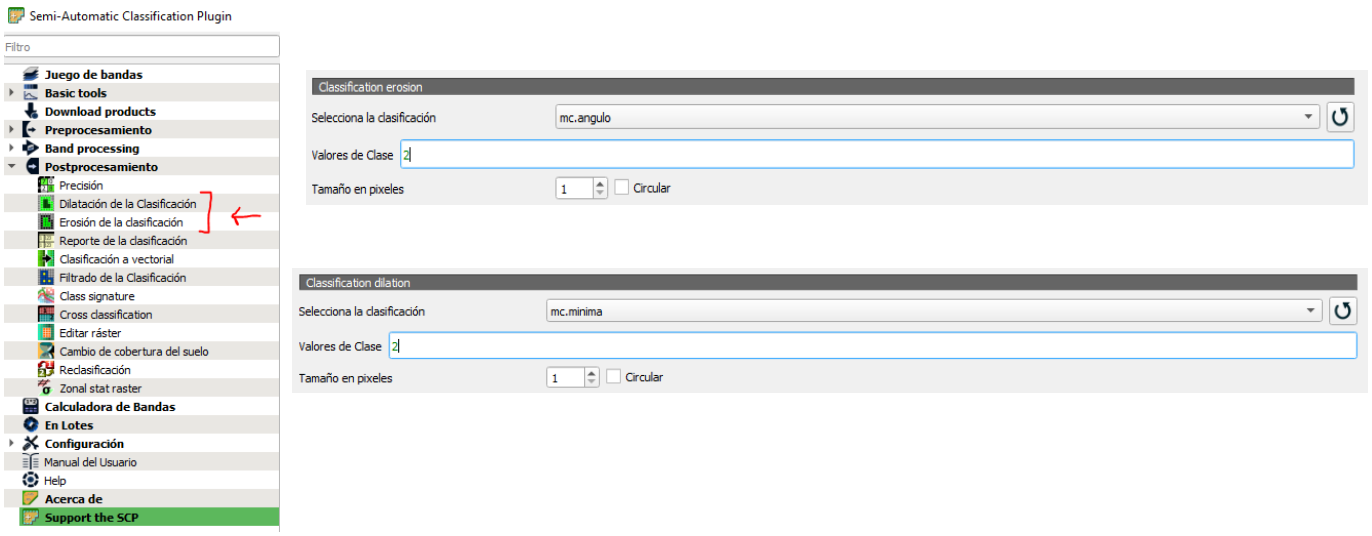
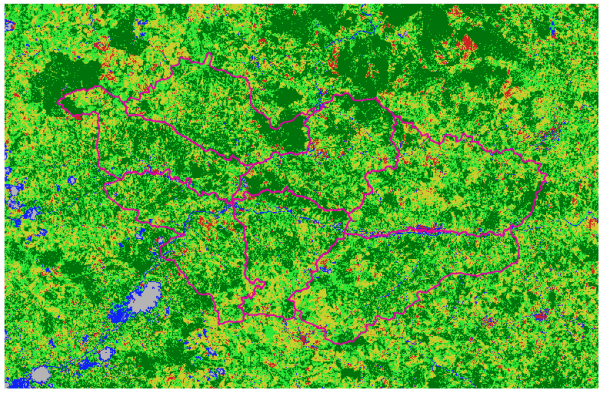
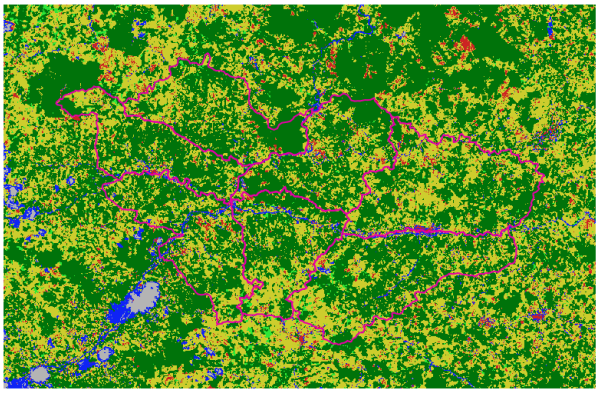


Figura 26. Interfaz Classification erosion and dilation. Fuente propia

Antes	Después
	
*Figura 12. Mapa de clasificación por mapeo del ángulo espectral por **QGIS**. Fuente propia.*	*Figura 27. Mapa de clasificación por mapeo del ángulo Post-procesado por **erosión**. Fuente propia*

Aplicando la erosión de la clasificación en nuestro mapa de clasificación de mapeo del ángulo espectral realizado por SCP y escogiendo el valor de clase 2 (vegetación), se obtiene un mapa donde se restringe los valores de vegetación (verde claro) y empiezan a ser ocupados por otros valores, principalmente por vegetación abundante y suelos.

Antes

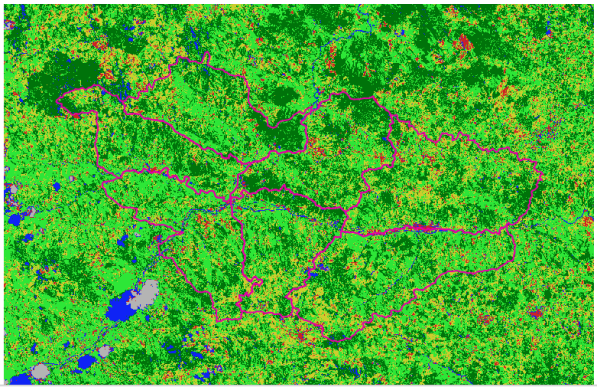


Figura 10. Mapa de clasificación por distancia mínima. Fuente propia.

Después

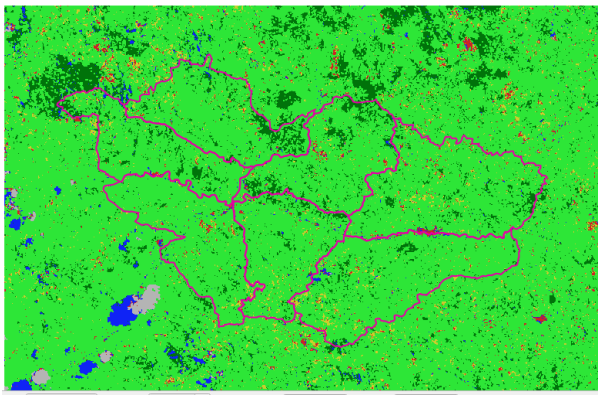


*Figura 28. Mapa de clasificación por distancia mínima. Post-procesado por **dilatación** Fuente propia*

Aplicando la dilatación de la clasificación en nuestro mapa de clasificación de distancia mínima realizado por SCP y escogiendo el valor de clase 2 (vegetación), se obtiene un mapa donde se aumentan los valores de vegetación (verde claro) y empiezan a ocupar los espacios de los otros valores, casi que termina ocupando toda la imagen.

3.2. Suavizar la clasificación realizada con ArcGIS Pro

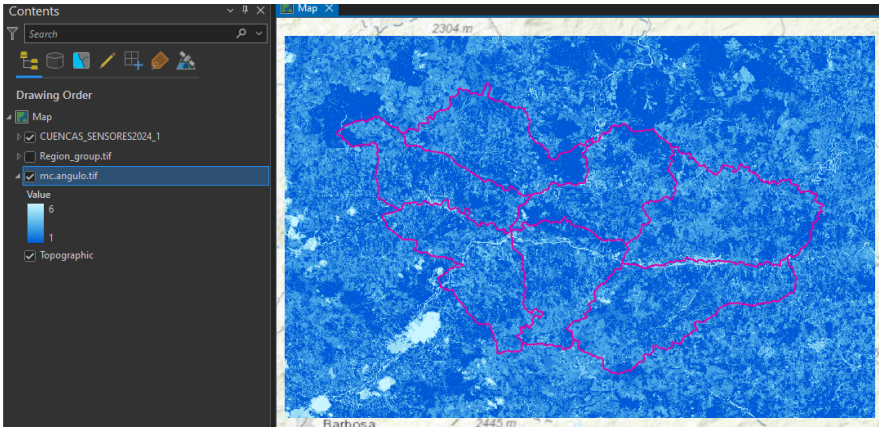


Figura 29. Mapa de clasificación de mapeo del ángulo en ArcGIS. Fuente propia

Para realizar la suavización de la clasificación con ArcGIS tomamos el mapa de clasificación de mapeo del ángulo espectral realizado por SCP en Qgis y lo pasamos a ArcGIS, una vez se carga el mapa aquí, nos dirigimos a la herramienta de Región group por medio de la siguiente ruta: **spatial analysis tools – Generalization – Region group.** Allí definimos en la opción: Number of neighbors to use defina FOUR y en Zone grouping method la opción WITHIN.

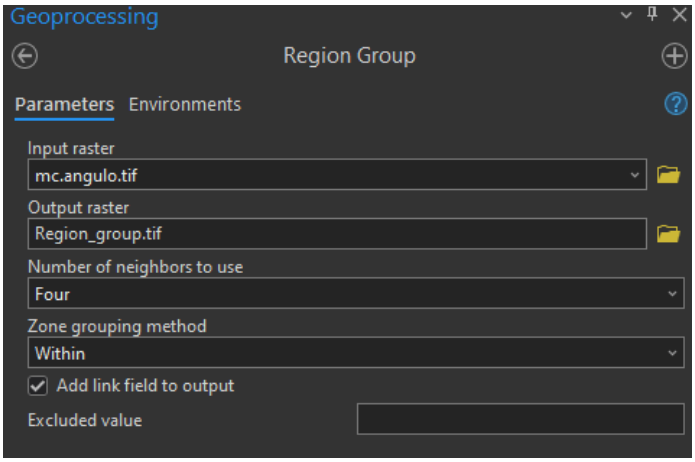


Figura 30. Region group. Fuente propia

Nos dirigimos a Set null por medio de la siguiente ruta **'analysis tools – Conditional – Set null'**, una vez allí seleccionamos del input raster, la imagen recién elaborada de ***'region_group.tif'*** y escribiremos una expresión que identifique el umbral, como Conteo < 4, además de escribir 1 en Input false ráster.

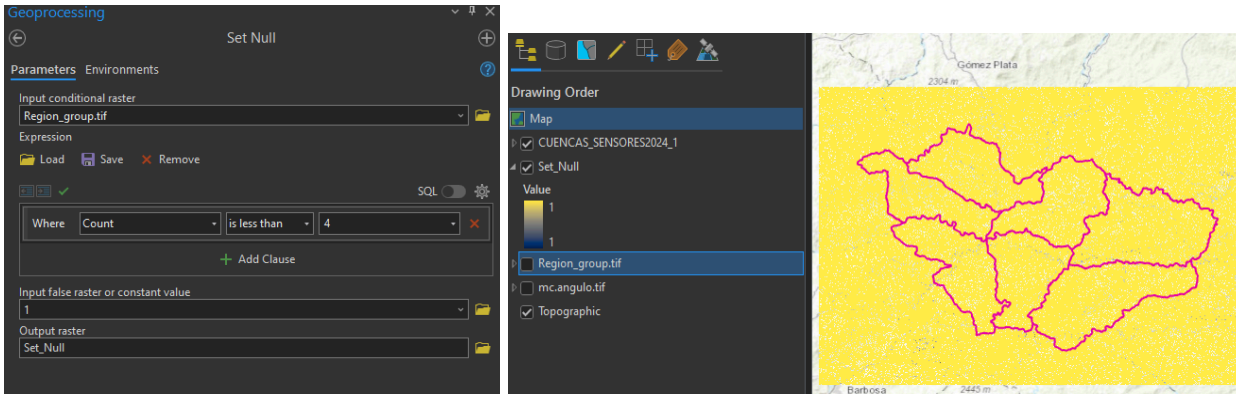


Figura 31. Set Null y mapa resultante. Fuente propia

Ahora nos dirigimos a **Nibble** por medio de la ruta **'Spatial analysis tools – Generalization – Nibble'** y ejecutaremos la siguiente función con los valores mostrados a continuación.

Desde Nibble y por medio de la ruta **'Spatial analysis tools – Generalization – Nibble**', ingresamos como en el input raster, la clasificación de mapeo del ángulo espectral y en el ráster mask ingresamos la imagen que obtuvimos en el Set Null.

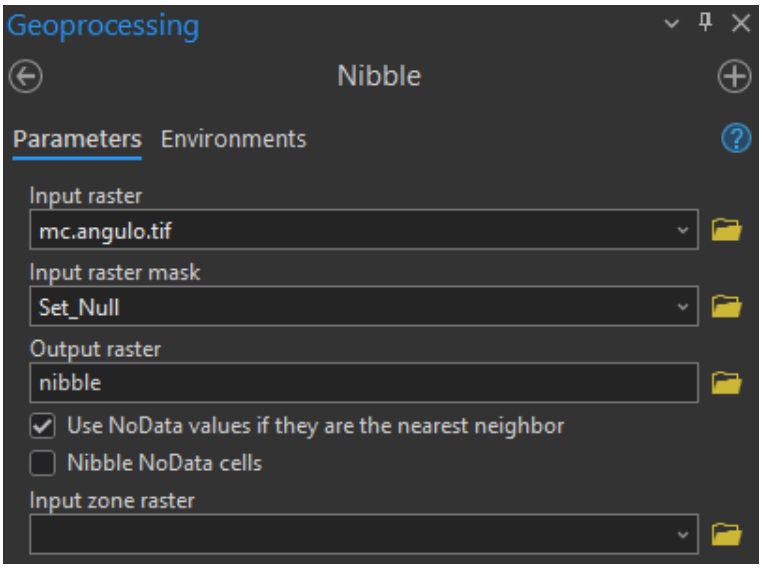


Figura 32. Interfaz Nibble. Fuente propia

De ésta manera obtuvimos el mapa suavizado de la clasificación de mapeo del ángulo espectral en regiones pequeñas con recuentos de píxeles inferiores a 4, como se pidió en el taller y éste fue el mapa que se obtuvo.

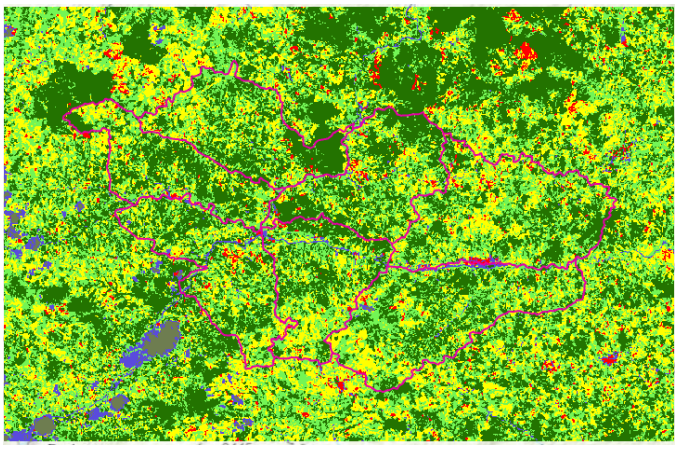
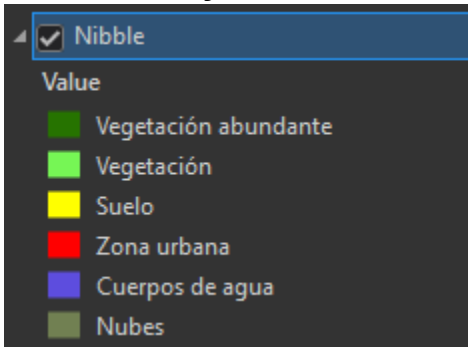


*Figura 33. Mapa de clasificación de mapeo del ángulo **suavizado** en ArcGIS Pro. Fuente propia*

Leyenda:



3.3. Filtrar el GIS Área Mínima Cartografiable

Para filtrar el área mínima cartografiable emplearemos el software de Arcgis Pro y usaremos el mapa de clasificación de mapeo del ángulo espectral realizado por SCP realizado en Qgis. Para esto es necesario convertir el ráster a **'shape file'**, para esto nos dirigimos a la herramienta 'Raster to polygon', en el input pondremos el mapa que calcularemos y en **field: Value.** De esta manera se generan miles de polígonos a los cuales le aplicaremos el área mínima cartografiable.

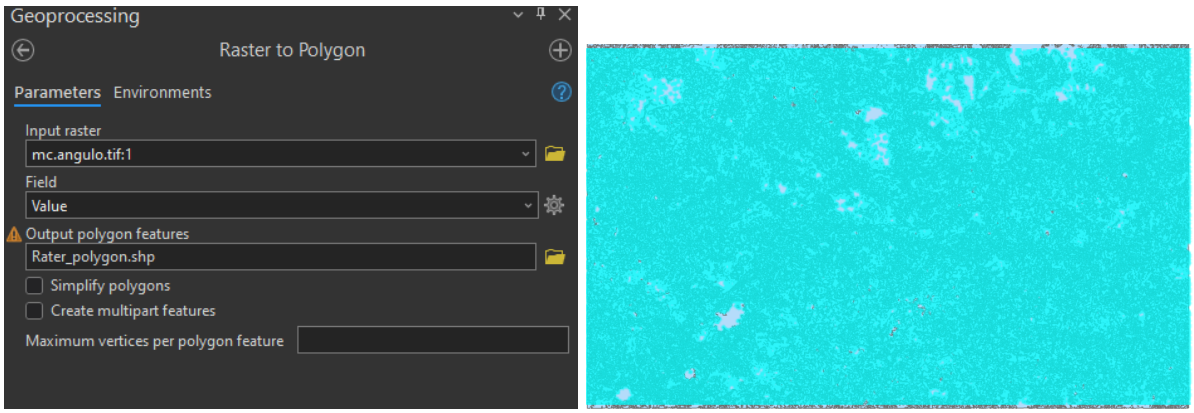


Figura 34. 'Raster to Polygon' y resultado. Fuente propia

Ahora abrimos la tabla de atributos de la nueva capa generada y añadimos un nuevo campo llamado **P1** que representa el área de cada polígono generado, que será de tipo doble, con precisión y escala cero.

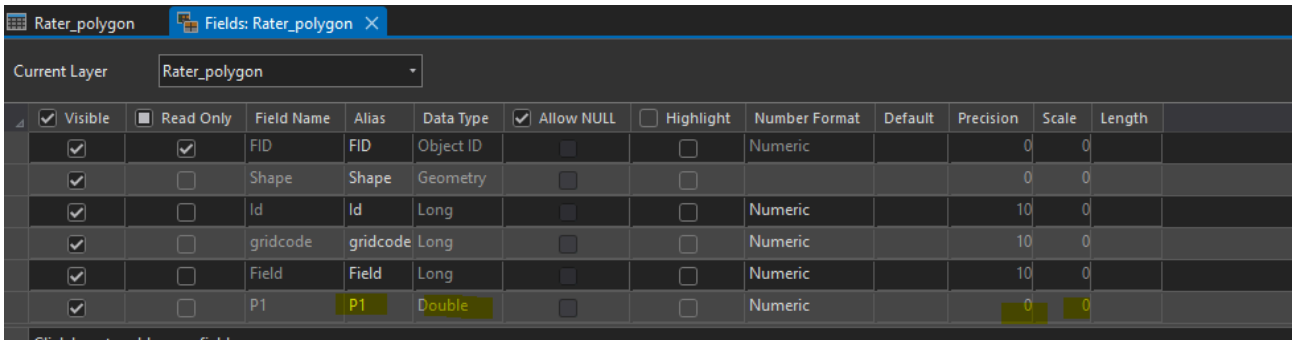


Figura 35. Tabla de atributos 'Raster to polygon'. Fuente propia

Una vez generado el nuevo campo P1 daremos click derecho sobre él y nos dirigiremos a Calculate Geometry, una vez allí pondremos como input el **shp** que generamos a partir del raster, en la geometría de atributos pondremos el campo P1 y en la propiedad área se configura en unidades de metro cuadrados con el sistema de coordenadas que veníamos trabajando con el mapa que tomamos.

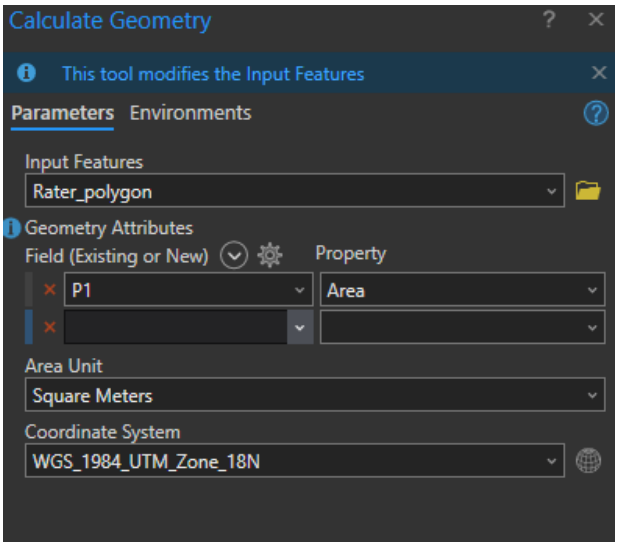
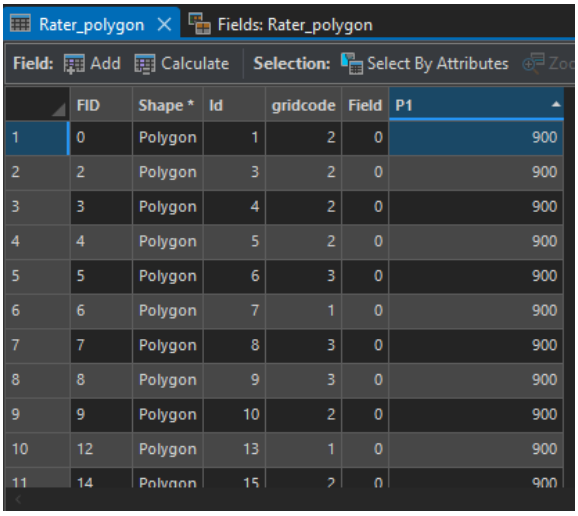


Figura 36. Cálculo del área de cada polígono. Fuente propia

Obtendremos en la tabla de atributos en el campo de P1 las áreas de cada uno de los polígonos como se ve en la imagen.



	FID	Shape *	Id	gridcode	Field	P1
1	0	Polygon	1	2	0	900
2	2	Polygon	3	2	0	900
3	3	Polygon	4	2	0	900
4	4	Polygon	5	2	0	900
5	5	Polygon	6	3	0	900
6	6	Polygon	7	1	0	900
7	7	Polygon	8	3	0	900
8	8	Polygon	9	3	0	900
9	9	Polygon	10	2	0	900
10	12	Polygon	13	1	0	900
11	14	Polygon	15	2	0	900

Figura 37. Tabla de atributos 2 'Raster to polygon'. Fuente propia

Finalmente, para filtrar el área mínima cartografiable, supondremos que nuestro mapa se encuentra en una escala de 1:50.000 y que nuestra área mínima cartografiable es de 40.000 m^2, entonces nos dirigimos a la pestaña **'select by attributes'** y subimos el SHP que contiene todos los polígonos con una selección de tipo: nueva selección y como expresión usaremos 'P1 Is less than or equal to 40.000' y procedemos a correrlo.

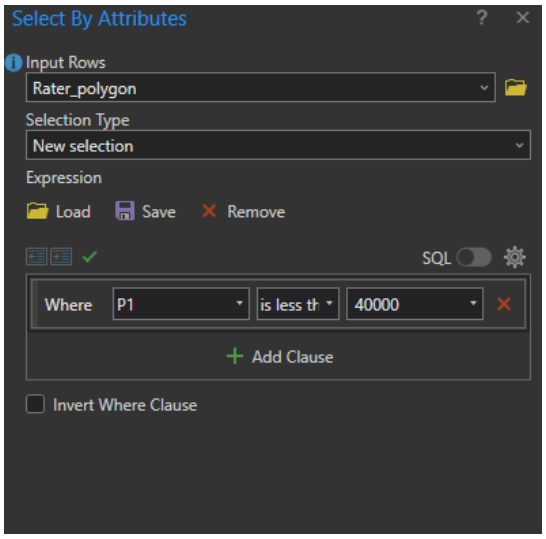


Figura 38. Selección de atributos. Fuente propia

Una vez realizado ésto, quedan seleccionados los polígonos con un área menor o igual a 40,000 m^2 (área mínima cartografiable), seleccionados tanto en la tabla en atributos como en el mapa, por lo que se realizó el filtro de manera satisfactoria.

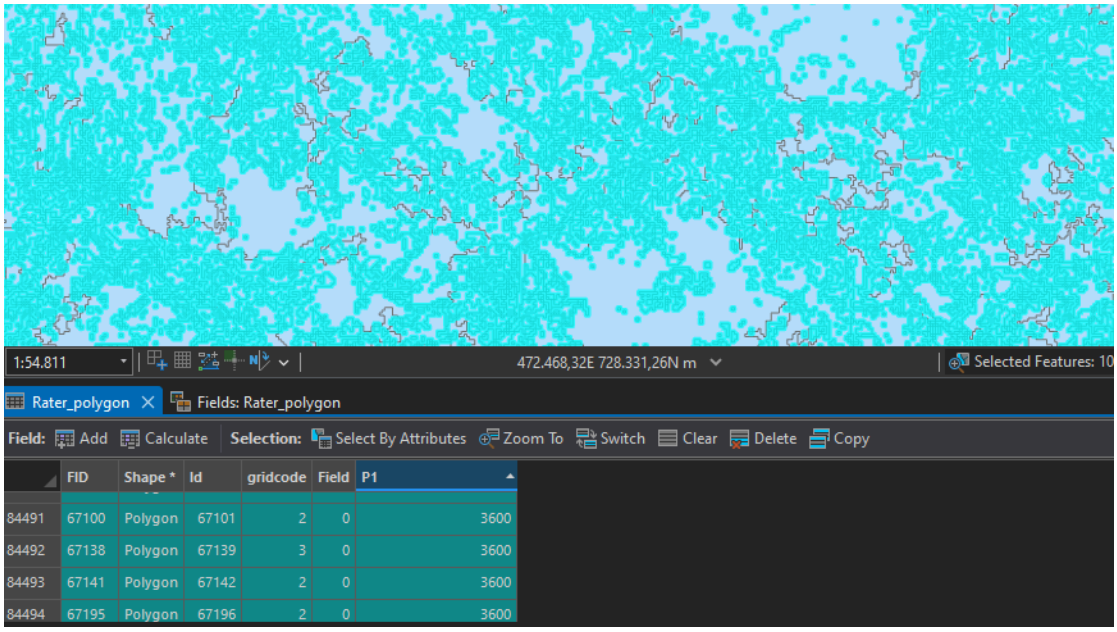


Figura 39. Resultado del filtro. Fuente propia

Una vez tengamos los atributos seleccionados nos dirigimos a la herramienta **‘Eliminate’** en donde procederemos a eliminar los atributos seleccionados, es decir, aquellos polígonos con área menor a 40,000 m^2 serán eliminados y se generará este cambio en una nueva capa.

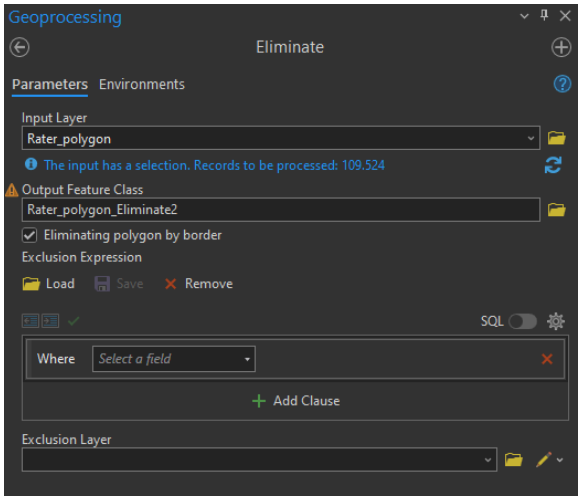


Figura 40. Interfaz Eliminate. Fuente propia.

A Continuación vemos en nuestra area de interés de color azul, aquellos poligonos que fueron seleccionados al presentar un area menor a 40,000 m^2 (Poligonos que fueron eliminados) y de amarillo aquellos poligonos que no fueron seleccionados al tener un área cartografiable mayor a 40,000 m^2.

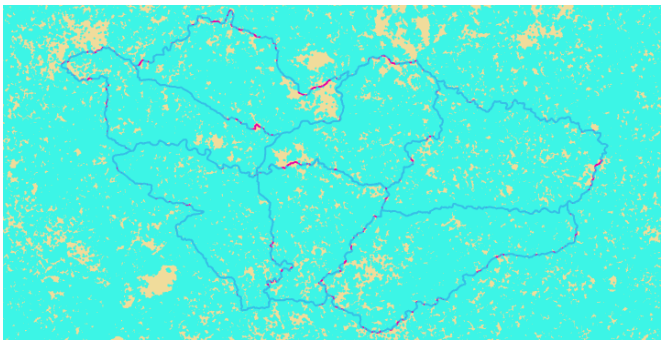


Figura 41. Mapa 'Raster to polygon' con polígonos seleccionados . Fuente propia.

Bibliografía:

• Gisadminbeers. (2018, 28 noviembre). Área mínima cartografiable en un mapa - Gis&Beers. Gis&Beers. http://www.gisandbeers.com/area-minima-cartografiable-mapa/

• Alonso, D. (2023b). Combinación de bandas en imágenes de satélite Landsat y Sentinel. MappingGIS. https://mappinggis.com/2019/05/combinaciones-de-bandas-en-imagenesde-satelite-landsat-y-sentinel/